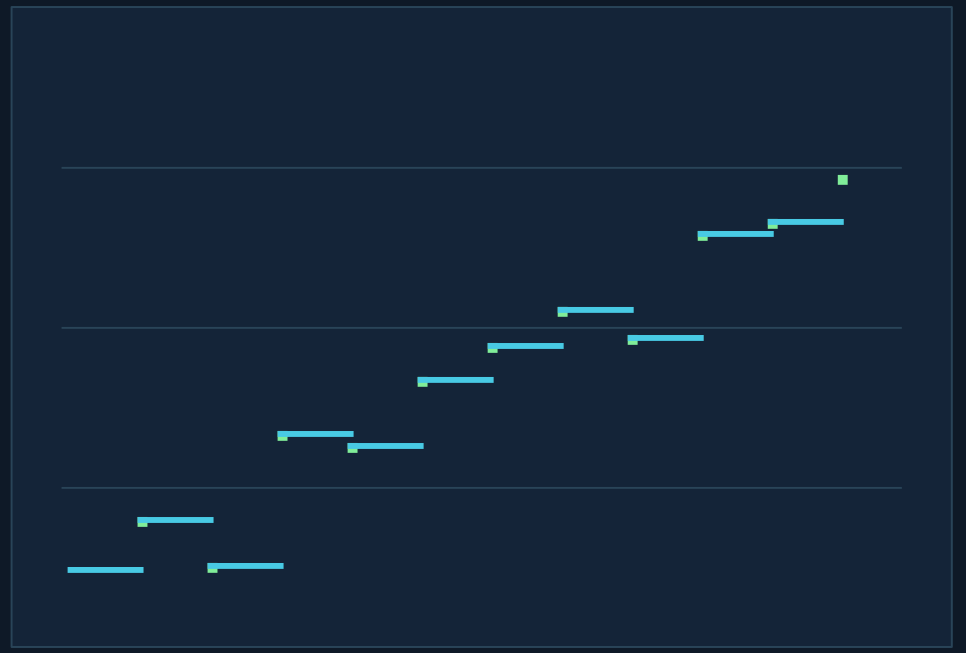
Машинное обучение: задача, данные и проверка прогноза

Новые партии наноэмульсии: от решения до честной ошибки



ПРОГНОЗ • НОВЫЕ КАМПАНИИ

Лекция 11 · 40 слайдов

Контракт прогноза новой партии

01 **Решение: выбрать рецепт до приготовления**

02 Цель: средний диаметр трёх отсчётов, нм

03 Будущее: новый день, тот же прибор и диапазон

Фиксируем решение, цель и новизну до просмотра метрик

Формальная цель оценки

01

Единица данных: одна партия

02

Модель обучена на прежних днях

03

Цель: ошибка на будущих днях

Тест должен представлять будущие условия применения

Число или категория

- Регрессия сохраняет измеренный диаметр в нм
- Классификация: «брак» по заранее заданному тесту
- Порог 135 нм здесь учебный, не норматив

ПРОВЕРЬТЕ

При пороге учитывайте повторяемость измерения

Какие признаки доступны до синтеза

Состав: сорт масла и доля компонента, мас. %

Режим: время обработки, мин

Изображение готовой партии появится позже

Для позднего прогноза допустимые входы меняются

Временная ось признака

01

Рецептура записана до запуска

02

Морфологию получают после приготовления

03

QC и диаметр известны после измерения

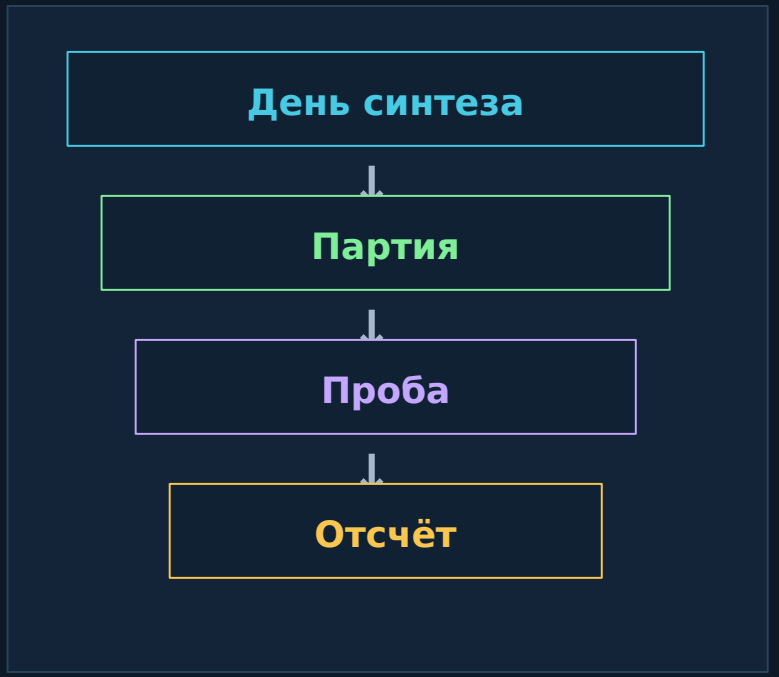
Поздний признак в ранней модели сообщает будущее

Уровни вложенности данных

День → партия → проба → измерение

Повторы партии разделяют её условия получения

Новый день требует удержать все его партии вместе



Почему повторы не заменяют синтезы

01

y = рецепт + день + партия + шум

02

Var(среднего) = 36 + 16 + 9/m

03

m = 1, 3, 9: 61, 55, 53 нм²

Новые измерения снижают только последний член

Таблица на уровне партии

- Одна строка: рецепт, ID дня и партии
- Цель: среднее трёх отсчётов, нм
- Храните SD и число измерений для контроля

ПРОВЕРЬТЕ

ID и технический номер не передавайте как X

Разбиение следует за применением

Новая партия знакомого дня: группа batch_id

Новый день: группа campaign_id

Новая поставка: группа supply_id

Перенос на другой прибор проверяют отдельно

Baseline должен быть доступен в работе

01

Константа: средний диаметр только train

02

Лабораторное правило допустимо, если известно до синтеза

03

Сравнение — на одних и тех же тестовых партиях

Выигрыш в MAE ещё не устанавливает причинность

Внешний тест будущих дней

Кампании 10 и 11 откладываем до настройки

Признаки, метрику и порог пользы задаём раньше

После выбора метода считаем один финальный отчёт



Внутренняя проверка по дням

01

На днях 0–9: GroupKFold(n_splits=5)

02

В проверочной части каждой складки два полных дня

03

Импутация, кодирование и Ridge переобучаются

Проверьте число и состав групп каждой складки

Псевдорепликация в тесте

- 144 отсчёта соответствуют лишь 48 партиям
- Случайное деление строк смешивает повторы
- При новом дне группируйте четыре партии дня

ПРОВЕРЬТЕ

Проверяйте ID по обе стороны каждой границы

Предобработка внутри складки

Медиану для заполнения пропусков считаем на train

Масштаб и кодирование учатся без тестовых строк

Отбор пиков по y выполняется внутри CV

Одна складка

Обучение: 2, 4, 6

Медиана равна 4

Проверка: заменяем пропуск на 4. Медиану сохраняем.

Три разных утечки

01

Целевой результат QC в предсинтезных входах

02

Отбор признаков по ответам всех кампаний

03

Выбор лучшего seed по финальным двум дням

Аудит времени появления и происхождения полей

Процедура выбора модели

01 **Отложить новые дни до анализа**

02 Подобрать alpha по групповой CV на прежних днях

03 Обучить на разработке и открыть тест один раз

best_score_ после подбора не финальная оценка

Из чего состоит Pipeline

01

Числа: пропуски и масштаб

02

Масло: кодирование категорий

03

Ridge: alpha = 0,1; 1; 10; 100

GridSearchCV обучает весь конвейер в каждой складке

Ручной расчёт MAE

Baseline: (17 + 3 + 12 + 28) / 4 = 15 нм

Модель: (4 + 4 + 7 + 7) / 4 = 5,5 нм

Четыре условные партии не оценивают редкие промахи

Размер партии, нм

Партия	Опыт	Прогноз
A	118	122
B	132	128
C	147	140
D	163	156

Базовый прогноз для всех четырёх партий равен 135 нм.

RMSE и смещение на тех же партиях

RMSE = √[(16 + 16 + 49 + 49) / 4]

Результат: около 5,70 нм

Средняя ошибка $\hat{y} - y = -3{,}5$ нм

Отдельно проверьте край диапазона и порог

Графики дополняют среднюю ошибку

01

Факт против прогноза: линия равенства

02

Подписанная ошибка против условий синтеза

03

Ошибки отдельно для дня 10 и дня 11

Общий MAE может скрыть сдвиг одного дня

Что именно усредняется

01 **MAE по партиям взвешивает каждую партию**

02 Среднее MAE по дням взвешивает каждый день

03 Неопределённость оценивают по независимым дням

Два тестовых дня не дают точного интервала

Интервалы имеют разный смысл

01

SD измерений: повторяемость внутри партии

02

Прогнозный интервал: результат новой партии

03

Интервал для средней ошибки по новым дням

Bootstrap по двум дням не создаст новые данные

Матрица ошибок для брака

Положительный класс: партия с браком

TP = найденный брак; FN = пропущенный брак

FP: годную партию направили на проверку.
TN: годную партию пропустили.

ПРОВЕРЬТЕ

Фиксируйте ориентацию y_true и y_pred

Accuracy скрывает пропуски брака

10 бракованных из 100; «все годны» даёт 90%

Но recall брака для такого правила равен нулю

Пример: TP=7, FN=3, FP=8, TN=82

Столбцы — прогноз модели

Факт	Брак	Годен
Брак	7 TP	3 FN
Годен	8 FP	82 TN

Итого 10 бракованных и 90 годных партий.

Precision и recall на числах

01

Precision брака = 7 / 15 ≈ 0,47

02

Recall брака = 7 / 10 = 0,70

03

Специфичность = 82 / 90 ≈ 0,91

Без числа положительных партий доли непрочны

Цена ошибки задаёт порог действия

01 **Пропуск брака стоит 10 условных единиц**

02 Лишняя проверка стоит 1; пример даёт 38

03 При калиброванной p порог = 1 / 11 ≈ 0,09

Цены и порог утверждают до финального теста

Калибровка и смена частоты брака

01

predict_proba не гарантирует частоту событий

02

Калибровка учится только на разработке

03

Новая поставка может изменить долю брака

Порог из старого процесса нуждается в проверке

Внутренняя и внешняя проверка

CV по дням оценивает похожие будущие дни

Финальный тест: последние две кампании

Поставка и другой прибор требуют нового теста



Сквозной пример: 12 кампаний

12 дней × 4 партии × 3 отсчёта = 144 измерения

После агрегации: 48 строк для регрессии

Обучение: 40 партий; тест: 8 партий

Числа генератора искусственные, не физический закон

Проверки в коде до обучения

01

batch_id уникален в таблице партий

02

ID дней разработки и теста не пересекаются

03

В каждой складке также сверяются ID дней

Хронологический тест не подбирают по seed

Настройка без доступа к тесту

01 **Четыре заранее выбранных значения alpha**

02 5 складок по двум дням для выбора

03 GridSearchCV заново обучает Pipeline

best_score_ выбирает модель, но не оценивает победителя

Ограничения восьми тестовых партий

01

Покажите все восемь факт–прогноз–ошибка

02

Средняя ошибка может зависеть от двух дней

03

Для нового прибора и сырья данных нет

Следующий шаг — новые независимые кампании

Прогноз не определяет эффект фактора

- Время обработки и состав могут быть смешаны
- Значимый коэффициент не доказывает механизм
- Факторный опыт меняет факторы по плану

ПРОВЕРЬТЕ

Причинный вывод требует отдельного дизайна

Паспорт области применения

Масла, интервалы долей и времени

Покрытие сочетаний факторов, даты, прибор

MAE по дням и число независимых кампаний

Флаг вне изученной области требует проверки

Мини-проект: постановка

01

Решение и момент получения входов

02

Иерархия: день, партия, технический отсчёт

03

Цель, единицы и правило агрегации

Если групп мало, планируйте их получение

Мини-проект: независимая проверка

01 **Baseline и Pipeline на одинаковых партиях**

02 MAE, RMSE и ошибки каждой кампании

03 График остатков и заранее записанный допуск

Отдельный опыт проверит поставку или прибор

Вопросы для обсуждения

01

Почему 144 отсчёта не равны 144 синтезам?

02

Что оценивает разбиение по campaign_id?

03

Можно ли решить по прогнозу 134 нм при пороге 135?

Укажите повторяемость, цену ошибок и новый опыт

Что делает прогноз проверяемым

- Контракт: решение, цель, момент, будущая группа
- Непересечение дней и полный Pipeline в CV
- Ошибка в нм, baseline и границы переноса

ПРОВЕРЬТЕ

Методы и выбор нового опыта — лекция 12

Источники и продолжение

scikit-learn: cross-validation и GroupKFold

scikit-learn: common pitfalls, Pipeline, metrics

Конспект 11: код, расчёт и научные ограничения

Лекция 12: методы и следующий эксперимент