Машинное обучение: модели и следующий эксперимент

Ансамбли, нейросети и осмысленный выбор опыта

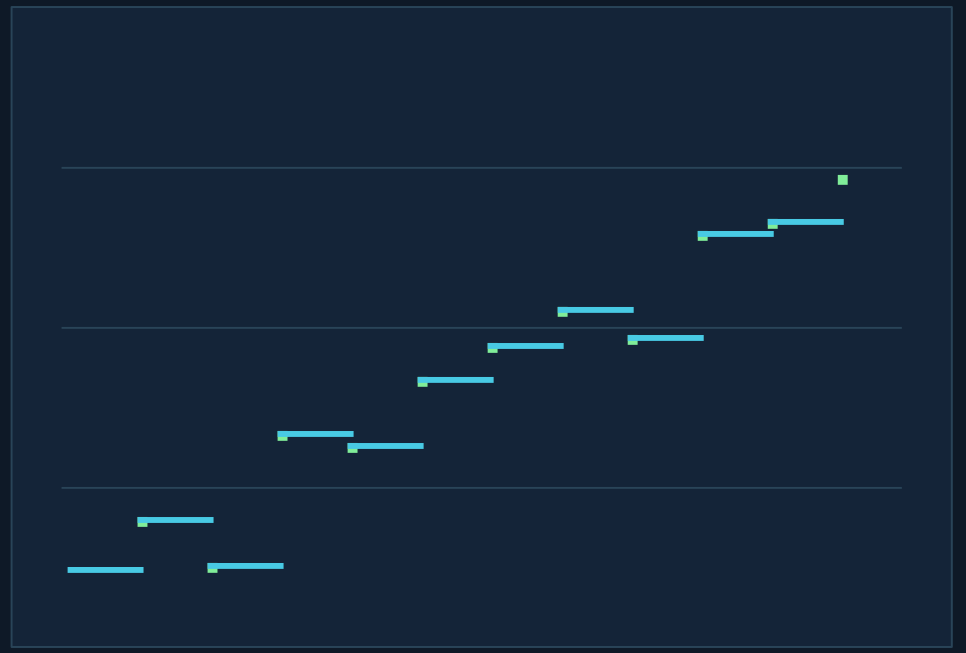


СХЕМА • больше данных / лучше проверка

Лекция 12 · 40 слайдов

От вопроса к набору методов

01 **Тип данных: табличные рецептуры или спектры**

02 Цель: прогноз свойства либо описание структуры

03 Проверка: те же независимые группы для всех методов

Сложность оправдана выигрышем на будущих партиях

Лестница моделей

01

Лабораторное правило и константа

02

Ridge или Lasso для числовых признаков

03

PLS для спектров; лес и бустинг для нелинейности

У одного набора данных не должно быть четырёх разных тестов

Линейная модель как отправная точка

- Коэффициенты связывают признаки с прогнозом
- Масштабы признаков влияют на штраф регуляризации
- Остатки выявляют недостающую структуру

ПРОВЕРЬТЕ

Коэффициент модели сам по себе не доказывает механизм

Ridge сдерживает нестабильные коэффициенты

Штраф L2 ограничивает большие коэффициенты

Коррелированные признаки делят вклад между собой

α подбирают внутри групповой CV

Масштабирование должно быть частью Pipeline

Lasso выбирает разреженное решение

01

Штраф L1 может занулить коэффициенты

02

При коррелированных переменных выбор неустойчив

03

Выбранная переменная не равна доказанной причине

Сравните устойчивость признаков между независимыми группами

Механистический baseline может победить

01 **Физический закон задаёт осмысленный прогноз**

02 ML может моделировать остаток физической модели

03 Обе модели проверяют на тех же новых партиях

Подгонка не замещает физическое ограничение

Почему спектры многомерны

01

Сотни каналов при десятках независимых образцов

02

Соседние длины волн коррелируют

03

Фон, прибор и подготовка часто влияют на весь спектр

Число каналов не увеличивает число независимых партий

PCA отвечает на вопрос об X

Компоненты максимизируют дисперсию признаков

Целевое свойство не участвует в расчёте

Большая дисперсия может быть дрейфом прибора



PC1 / PC2: источник вариации?

Проверка смысла PCA

Раскрасьте точки по партии, дню и прибору

Сравните нагрузки важных каналов с физикой спектра

Проверьте устойчивость к масштабированию и фону

Визуальное разделение не является внешней проверкой

PLS учитывает X и y

Компоненты строятся для прогнозной связи

Число компонент подбирают только на разработке

Нужен отдельный тест новых образцов



Пример: искусственные спектры

01 **24 канала с коррелированным пиком**

02 30 независимых партий с известным свойством

03 1–4 компоненты сравнивают групповой CV

Числа демонстрируют API, а не химическую калибровку

Предобработка спектра без утечки

01

Физически фиксированный протокол можно применить ко всем файлам

02

Обучаемые параметры оценки — внутри складки

03

Отбор каналов по y на всём наборе запрещён

Параметры из теста не должны попадать в обучение

Дерево: разделения по порогам

- Пороговые взаимодействия читаются по ветвям
- Глубокое дерево легко подстроить под шум
- Ограничьте max_depth и min_samples_leaf

ПРОВЕРЬТЕ

Новые партии проверяют устойчивость порогов

Лес: усреднение многих деревьев

Для регрессии усредняем прогнозы деревьев

Деревья строятся на случайных подвыборках с выбором признаков

Bootstrap строк не создаёт новых физических партий

Одна новая партия

Дерево	Прогноз, нм
1	116
2	122
3	119

Прогноз леса: 119 нм

Среднее трёх прогнозов.

Лес и бустинг: два способа собрать деревья

01

Лес: независимые деревья, средний прогноз

02

Бустинг: каждое дерево исправляет прежние ошибки

03

Оба метода проверяют на тех же новых партиях

Больше деревьев не означает больше экспериментов

Бустинг: четыре условных опыта

01 **Температура: 80, 85, 95, 100 °C**

02 Свойство: 4, 6, 10, 12 усл. ед.

03 Первая модель: среднее $F_0 = 8$ для всех

Исходный MAE = (4 + 2 + 2 + 4) / 4 = 3

Первое дерево учится на остатках

01

$y - F_0 = -4, -2, +2, +4$

02

Порог 90 °C разделяет низкие и высокие T

03

Средний остаток: −3 слева, +3 справа

При квадратичной потере следующее дерево приближает остатки.

После одного шага бустинга

$F_1 = F_0 + 0{,}5 \cdot \text{дерево}$

Прогноз: 6,5; 6,5; 9,5; 9,5

Новые остатки: −2,5; −0,5; +0,5; +2,5

ПРОВЕРЬТЕ

MAE уменьшился с 3 до 1,5 усл. ед.

Что регулирует сложность бустинга

Мелкое дерево исправляет простой остаток

learning_rate задаёт размер каждого шага

n_estimators задаёт число последовательных шагов

Выбирайте настройки на групповой проверке

Лес против бустинга: честный протокол

01

Один и тот же тест новых партий для всех моделей

02

Одинаковая метрика и групповые складки разработки

03

Встроенную случайную остановку проверяйте отдельно

Сообщите ошибку каждой кампании, а не только среднюю

Неопределённость прогноза

01 **Различайте средний прогноз и новый результат**

02 Учтите разброс партий и ошибку измерения

03 Покрытие интервала проверяйте на новых партиях

Число ±σ без определения источника неопределённости малоинформативно

PCA внутри прогнозного Pipeline

01

PCA.fit на всей таблице видит распределение теста

02

В каждой складке scaler и PCA обучаются заново

03

Цель используется только на этапе supervised модели

Unsupervised не означает безопасно до разбиения

Кластеризация: геометрия данных

KMeans требует число кластеров заранее

Результат зависит от масштаба и признаков

Номера кластеров произвольны



Silhouette и его предел

Оценивает компактность и отделение групп

Может предпочесть структуру прибора или дня

Не подтверждает физический механизм

Сопоставьте кластеры с независимыми измерениями

Сдвиг прибора как ложное открытие

01

Два прибора дают разные спектральные фоны

02

PCA и KMeans могут разделить приборы

03

Прогноз свойства затем теряет качество вне прибора

Раскрасьте PCA по прибору до именования кластеров

Kaggle: pH по трём каналам RGB

01 **Входы: R, G, B; цель: pH раствора**

02 Это таблица цветов, исходные пиксели не заявлены

03 Проверьте колонки, диапазоны и повторяющиеся строки

Цвет зависит также от освещения и съёмки

pH: какие модели сравнить

01

Константа и Ridge: простые отправные точки

02

Неглубокий бустинг: нелинейная связь RGB и pH

03

Малая сеть 3 → 8 → 1: факультативное сравнение

MAE в pH; перенос на новый прибор требует новых съёмок

Активное обучение

Модель предлагает условия и оценивает неопределённость

Человек проверяет область, безопасность и цену

Новая партия обновляет данные и прогноз



Активный выбор: прогноз и неопределённость

A: 95 ± 2; B: 90 ± 8; числа условные

При score = прогноз + неопределённость: 97 и 98

B изучает более неопределённый участок

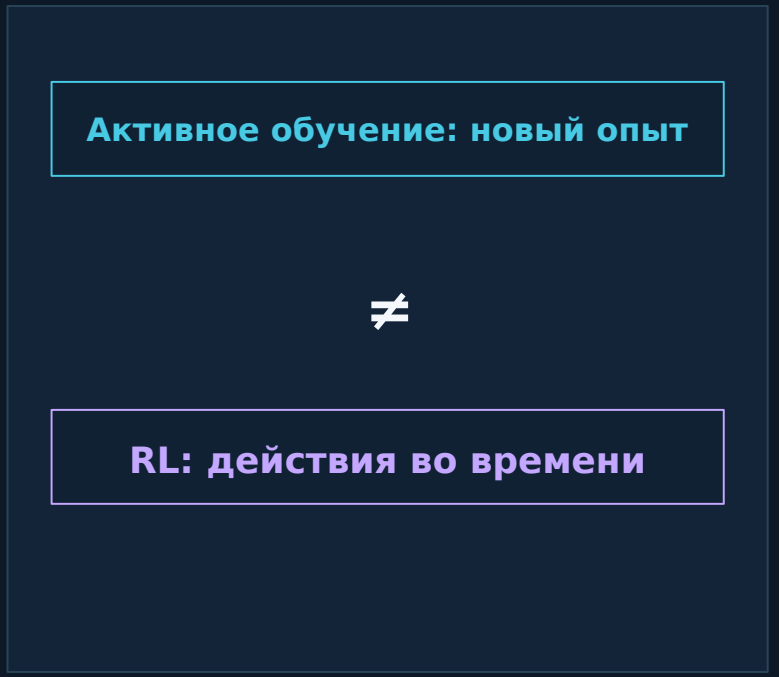
Оцените допустимость и повторите спорный опыт

Активное обучение и RL — разные постановки

Активное обучение выбирает информативный опыт

RL выбирает действия в последовательности состояний

Обе постановки требуют явной цели и ограничений



Нейронная сеть вычисляет прогноз

01 **Скрытый слой: $h = \mathrm{ReLU}(W_1 x + b_1)$**

02 Выход регрессии: $\hat{y} = W_2 h + b_2$

03 Веса обновляются по градиенту функции потерь

Нелинейность даёт гибкость и риск переобучения

Малая сеть для RGB: 3 → 8 → 1

01

Три входа и восемь скрытых нейронов

02

(3 + 1) × 8 + (8 + 1) = 41 параметр

03

Масштаб и подбор эпох учатся только на train

На небольшой таблице Ridge может быть устойчивее

Kaggle: липофильность молекул

- Цель: экспериментальный log D при pH 7,4
- Вход: молекулярные дескрипторы и структура
- Ноутбук сравнивает SVR, Keras и модели поверх неё

ПРОВЕРЬТЕ

Новая химическая серия — отдельный тест переноса

Утечка: преобразование до разбиения

StandardScaler.fit на всех дескрипторах

KernelPCA.fit тоже до train_test_split

Тестовые X участвуют в подготовке модели

Преобразования без y также влияют на честность теста

Вторая утечка и исправленный порядок

01

После split снова объединены X_train и X_test

02

Scaler и KernelPCA обучены на объединении

03

Сначала split, затем каждый fit внутри CV на train

Удержанный тест оценивают однократно после выбора

RL: постановка для процесса во времени

01 **Состояние: доступная сейчас T и показания датчика**

02 Действие: разрешённое изменение мощности нагрева

03 Награда: итоговое качество с затратой и штрафом

Нужны траектории и проверенный симулятор

Два действия и отложенный результат

01

Быстро: сейчас +3, затем лучший итог −6

02

Плавно: сейчас 0, затем лучший итог +4

03

При $\gamma = 0{,}9$: $Q = -2{,}4$ против $+3{,}6$

Числа условные; это не режим для установки

Метод выбирают по задаче и проверке

- Ансамбли и сеть сравнивают на одном честном тесте
- Активный выбор предлагает следующий эксперимент
- RL задаёт последовательность действий во времени

ПРОВЕРЬТЕ

Код и задания по Kaggle — в конспекте и домашней работе

Источники и дальнейшее чтение

scikit-learn: PLS, ensembles и MLP

Kaggle: pH-recognition; Lipophilicity notebook

MoleculeNet: исходная задача log D

Подробности и задания — в конспекте лекции 12